Analisando Dados com Python

Como nasceu esse workshop?

- GEDS - Grupo de Estudos em Data Science, integrantes do Pyladies São Paulo
- Trilha e materiais
- A missão foi estudar Ciência de Dados, disponibilizar o material para a comunidade e incentivar outras mulheres a formarem grupos de estudos de temas de interesse
- Material adaptado dessa 1a versão do Workshop feito pelas integrantes do GEDS

Agenda

- ➔ Contexto
- ➔ Tipos de Dados
- ➔ Introdução ao pacote Pandas
- ➔ Estatística Descritiva
- ➔ Variabilidade dos dados
- ➔ Introdução à Visualização

pyladies São Paulo

Contexto

Elementos importantes em uma análise de dados:

- Definição de Objetivos
- Limpeza e Preparação dos Dados - qualidade
- Exploração de Dados
- Análise Estatística
- Visualização de Dados
- Interpretação de Resultados
- Comunicação dos Insights - apoio para Tomada de Decisão
- Ética e Privacidade
- Atualização e Monitoramento

pyladies São Paulo

Contexto

A análise de dados não é apenas sobre a **coleta e manipulação de números**; é sobre **como usar esses dados para comunicar** informações de maneira significativa e para tomada de decisões.

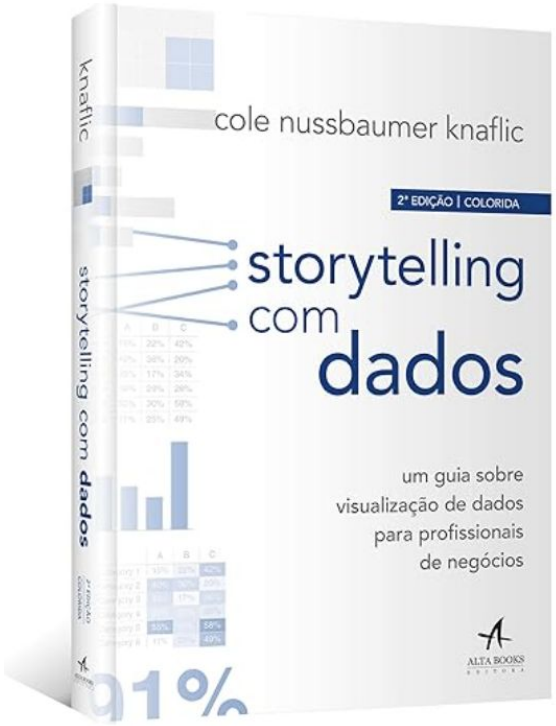

pyladies São Paulo

Google Colaboratory

O Colab segue o mesmo padrão do Jupyter Notebook. Nele é possível adicionar células de código, texto, importar arquivos etc. Para ter acesso ao Google Colab, basta logar na sua conta Google e acessar o link https://colab.research.google.com;

pyladies
São Paulo

Tipos de Dados

Tipos de dados

Quantitativos - Quantifica ou mede

Discretos:
Assumem valores em um conjunto especificado de números.

Contínuos:
Assumem valores em um intervalo contínuo de números.

Qualitativos - Característica ou qualidade

Nominal:
Característica que não possui ordem.

Ordinal:
Característica que possui uma ordem de grandeza.

pyladies São Paulo

Tipos de Dados

Quantitativos

Discretos:
- Quantidade de pessoas na sala?
- Quantidade de dias no mês?

Contínuos:
- Qual sua altura?
- Qual a distância daqui até sua casa?

Qualitativos

Nominal:
- Qual seu Estado? (SP, MG, RJ, Outros)
- Qual gênero você se identifica?

Ordinal:
- Avaliação curso (Ruim a Ótimo).
- Qual seu nível de escolaridade?

pyladies São Paulo

Tipos de Dados - Exemplo PyLadies

ID	Estado Origem	Idade	Escolaridade	Trabalha como Programadora	Renda Mensal
1	SP	36	4	S	3737,52
2	SP	25	2	N	400,00
3	MG	34	3	S	2366,14
4	RJ	23	3	S	2841,29
5	SP	31	4	N	800
6	SP	34	5	S	3433,02
7	SP	39	5	S	2752,74
8	PE	24	3	S	3682,33
9	RJ	29	3	S	2359,28
10	SP	27	3	S	2119,15
11	SP	30	3	S	3326,79
12	SP	25	4	S	2684,05
13	SP	23	2	S	3507,84
14	SP	16	1	N	0
15	SP	36	4	N	800

Legenda Escolaridade

1	Ensino Medio Completo
2	Graduanda
3	Graduação Completa
4	Pós graduanda
5	Pós graduação completa

Dados meramente ilustrativos.

pyladies São Paulo

Tipos de Dados - Dados Qualitativos

ID	Estado Origem	Idade	Escolaridade	Trabalha como Programadora	Renda Mensal
1	SP	36	4	S	3737,52
2	SP	25	2	N	400,00
3	MG	34	3	S	2366,14
4	RJ	31	4	N	2841,29
5	SP	31	4	N	800
6	SP	34	5	S	3433,02
7	SP	39	5	S	2752,74
8	PE	24	3	S	3682,33
9	RJ	29	3	S	2359,28
10	SP	27	3	S	2119,15
11	SP	30	3	S	3326,79
12	SP	25	4	S	2684,05
13	SP	23	2	S	3507,84
14	SP	16	1	N	0
15	SP	36	4	N	800

Dados Qualitativos

Legenda Escolaridade

1	Ensino Medio Completo
2	Graduanda
3	Graduação Completa
4	Pós graduanda
5	Pós graduação completa

pyladies São Paulo

Tipos de Dados - Categóricos

ID	Estado Origem	Idade	Escolaridade	Trabalha como Programadora	Renda Mensal
1	SP	36	4	S	3737,52
2	SP	25	2	N	400,00
3	MG	34	3	S	2366,14
4	SP	23	4	S	2841,29
5	SP	31	4	N	800
6	SP	34	5	S	3433,02
7	SP	39	5	S	2752,74
8	PE	24	3	S	3682,33
9	RJ	29	3	S	2359,28
10	SP	27	3	S	2119,15
11	SP	30	3	S	3326,79
12	SP	25	4	S	2684,05
13	SP	23	2	S	3507,84
14	SP	16	1	N	0
15	SP	36	4	N	800

Nominal **Ordinal** **Nominal**

Legenda Escolaridade

1	Ensino Medio Completo
2	Graduanda
3	Graduação Completa
4	Pós graduanda
5	Pós graduação completa

pyladies São Paulo

Tipos de Dados - Dados Quantitativos

ID	Estado Origem	Idade	Escolaridade	Trabalha como Programadora	Renda Mensal
1	SP	36	4	S	3737,52
2	SP	25	2	N	400,00
3	MG	34	3	S	2366,14
4	RJ	23			1,29
5	SP	31			00
6	SP	34	5	S	3433,02
7	SP	39	5	S	2752,74
8	PE	24	3	S	3682,33
9	RJ	29	3	S	2359,28
10	SP	27	3	S	2119,15
11	SP	30	3	S	3326,79
12	SP	25	4	S	2684,05
13	SP	23	2	S	3507,84
14	SP	16	1	N	0
15	SP	36	4	N	800

Dados Quantitativos

Legenda Escolaridade

1	Ensino Medio Completo
2	Graduanda
3	Graduação Completa
4	Pós graduanda
5	Pós graduação completa

pyladies São Paulo

Tipos de Dados - Numéricos

ID	Estado Origem	Idade	Escolaridade	Trabalha como Programadora	Renda Mensal
1	SP	36	4	S	3737,52
2	SP	25	2	N	400,00
3	MG	34	3	S	2366,14
4	RJ	39	3	S	2752,74
5	SP	31	4	N	800
6	SP	34	5	S	3433,02
7	SP	39	5	S	2752,74
8	PE	24	3	S	3682,33
9	RJ	29	3	S	2359,28
10	SP	27	3	S	2119,15
11	SP	30	3	S	3326,79
12	SP	25	4	S	2684,05
13	SP	23	2	S	3507,84
14	SP	16	1	N	0
15	SP	36	4	N	800

Discreto

Contínuo

Legenda Escolaridade

1	Ensino Medio Completo
2	Graduanda
3	Graduação Completa
4	Pós graduanda
5	Pós graduação completa

pyladies São Paulo

Trabalhando com Pandas

O acrônimo Pandas vem da combinação de *Panel Data* e *Python Data Analysis**.

- Dados de Painel - Python para Análise de Dados

pyladies São Paulo

Trabalhando com Pandas

Pandas é uma biblioteca de código aberto que fornece estruturas de dados de alto desempenho e fáceis de usar e ferramentas de análise de dados para a linguagem de programação Python.

https://pandas.pydata.org/

pyladies São Paulo

Primeiro Passo:

1. Abrir as bibliotecas que você utilizará
2. Subir o arquivo que possui seus dados

```
[ ]  #abrindo as bibliotecas que serão utilizadas
     import pandas as pd
     import matplotlib.pyplot as plt
     from google.colab import files
     uploaded = files.upload()
```

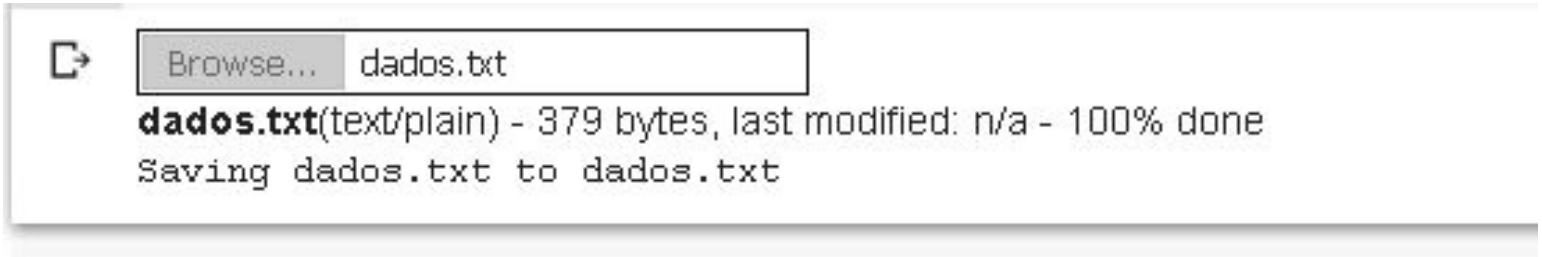

pyladies São Paulo

Abrindo o arquivo:

Importando um CSV para o Colab:

CSV - Comma-Separated Values

vírgula separando valor

pd.read_csv('nome_arquivo', sep = ';', decimal = ',')

```
# Transformando o arquivo importando em um dataframe
  dados_pyladies = pd.read_csv('dados.txt', sep=';', decimal = ',')
```

Argumentos	
separador	;
decimal	,

pyladies São Paulo

Visualizando o arquivo:

nome_dataframe.head()

```
#para ver as cinco primeiras linhas
dados_pyladies.head()
```

	Estado Origem	Idade	Escolaridade	Trabalha_como_Programadora	Renda_Mensal
0	SP	36	4	S	3737.52
1	SP	25	2	N	400.00
2	MG	34	3	S	2366.14
3	RJ	23	3	S	2841.29
4	SP	31	4	N	800.00

pyladies São Paulo

Visualizando o arquivo:

nome_dataframe.tail()

```
[22] # para ver as cinco últimas linhas
     dados_pyladies.tail()
```

	Estado Origem	Idade	Escolaridade	Trabalha_como_Programadora	Renda_Mensal
10	SP	30	3	S	3326.79
11	SP	25	4	S	2684.05
12	SP	23	2	S	3507.84
13	SP	16	1	N	0.00
14	SP	36	4	N	800.00

pyladies São Paulo

As Estruturas dos Dados:

O que é um dataframe??

DataFrame é uma estrutura de dados bidimensional - parecida com uma tabela de excel ou um banco de dados.

pyladies São Paulo

As Estruturas dos Dados:

Estrutura de dados bidimensional (colunas e linhas) cujo índice começa no **zero.**

O dataframe contém colunas que armazenam diferentes tipos de informações (string, float, integer e etc)

Ele é uma classe de objeto da biblioteca Pandas.

dataframe

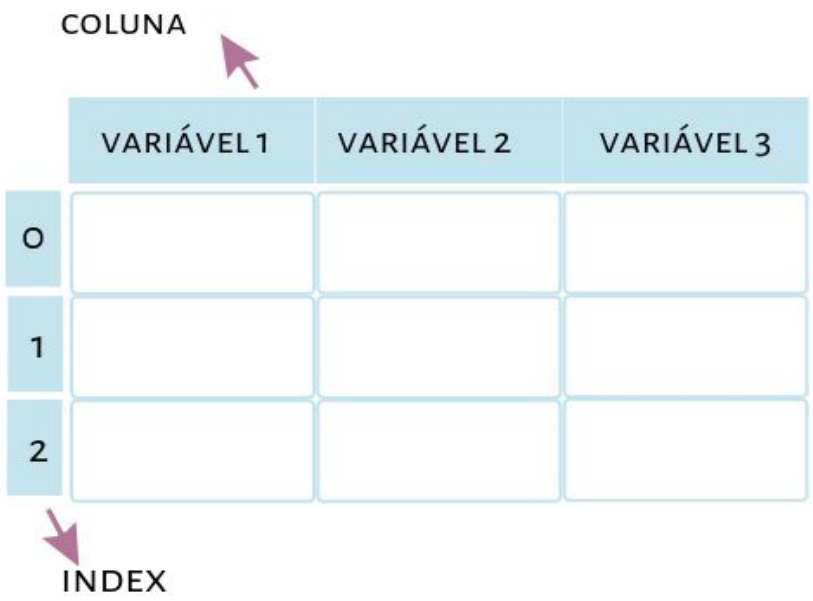

pyladies São Paulo

As Estruturas dos Dados:

E o series ??

DataSerie é estrutura unidimensional - como uma coluna do excel

pyladies São Paulo

As Estrutura dos Dados

Series

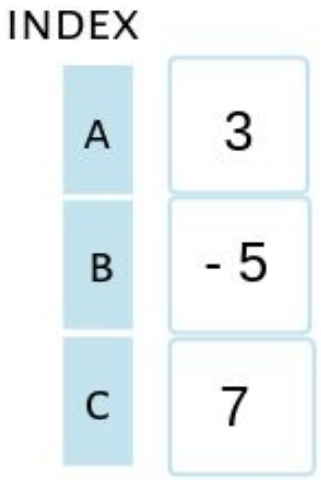

Um array unidimensional e rotulado capaz de armazenar qualquer tipo de dado.

```
s = pd.Series([3,-5,7,4], index = ['a','b','c','d'])
print(s)
```

```
a    3
b   -5
c    7
d    4
dtype: int64
```

pyladies São Paulo

As Estrutura dos Dados:

Linhas e Colunas

nome_dataframe.shape

```
dados_pyladies.shape
```

```
(15, 5)
```

Variáveis (colunas)

nome_dataframe.columns

```
dados_pyladies.columns
```

```
Index(['Estado Origem ', 'Idade', 'Escolaridade', 'Trabalha_como_Programadora',
       'Renda_Mensal'],
      dtype='object')
```

pyladies São Paulo

Conhecendo os Dados:

Informações Gerais

nome_dataframe.info()

```
dados_pyladies.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 15 entries, 0 to 14
Data columns (total 5 columns):
Estado Origem                  15 non-null object
Idade                          15 non-null int64
Escolaridade                   15 non-null int64
Trabalha_como_Programadora     15 non-null object
Renda_Mensal                   15 non-null float64
dtypes: float64(1), int64(2), object(2)
memory usage: 680.0+ bytes
```

pyladies São Paulo

Selecionando uma Variável (coluna):

nome_dataframe['coluna']

```
dados_pyladies['Estado Origem ']
```

```
0     SP
1     SP
2     MG
3     RJ
4     SP
5     SP
6     SP
7     PE
8     RJ
9     SP
10    SP
11    SP
12    SP
13    SP
14    SP
Name: Estado Origem , dtype: object
```

Lembrando que uma coluna de dataframe é uma series.

pyladies São Paulo

Selecionando duas ou mais variáveis (coluna):

nome_dataframe[['coluna', 'coluna2', 'colunaX']]

```
[19] dados_pyladies[['Estado Origem ', 'Escolaridade', 'Idade']]
```

	Estado Origem	Escolaridade	Idade
0	SP	4	36
1	SP	2	25
2	MG	3	34
3	RJ	3	23
4	SP	4	31
5	SP	5	34
6	SP	5	39
7	PE	3	24
8	RJ	3	29
9	SP	3	27
10	SP	3	30
11	SP	4	25
12	SP	2	23
13	SP	1	16
14	SP	4	36

pyladies São Paulo

Filtrando um dataframe:

nome_dataframe[nome_dataframe['coluna'] == condição]

```
dados_pyladies[dados_pyladies['Trabalha_como_Programadora'] == 'S']
```

	ID	Estado Origem	Idade	Escolaridade	Trabalha_como_Programadora	Renda_Mensal
0	1	SP	36	4	S	3737,52
2	3	MG	34	3	S	2366,14
3	4	RJ	23	3	S	2841,29
5	6	SP	34	5	S	3433,02
6	7	SP	39	5	S	2752,74
7	8	PE	24	3	S	3682,33
8	9	RJ	29	3	S	2359,28
9	10	SP	27	3	S	2119,15
10	11	SP	30	3	S	3326,79
11	12	SP	25	4	S	2684,05
12	13	SP	23	2	S	3507,84

Aqui você insere a condição para o filtro que você quer. Se a condição for um texto, não se esqueça das aspas!

Aqui você coloca o operador lógico que atende o filtro que você precisa.

pyladies São Paulo

Estatística

pyladies São Paulo

População e amostra

População é um conjunto de objetos, pessoas, itens sobre os quais deseja-se fazer inferências.

Amostra é um subconjunto de objetos, pessoas ou itens que representam a população.

Com uma amostra representativa, é possível inferir sobre essa população.

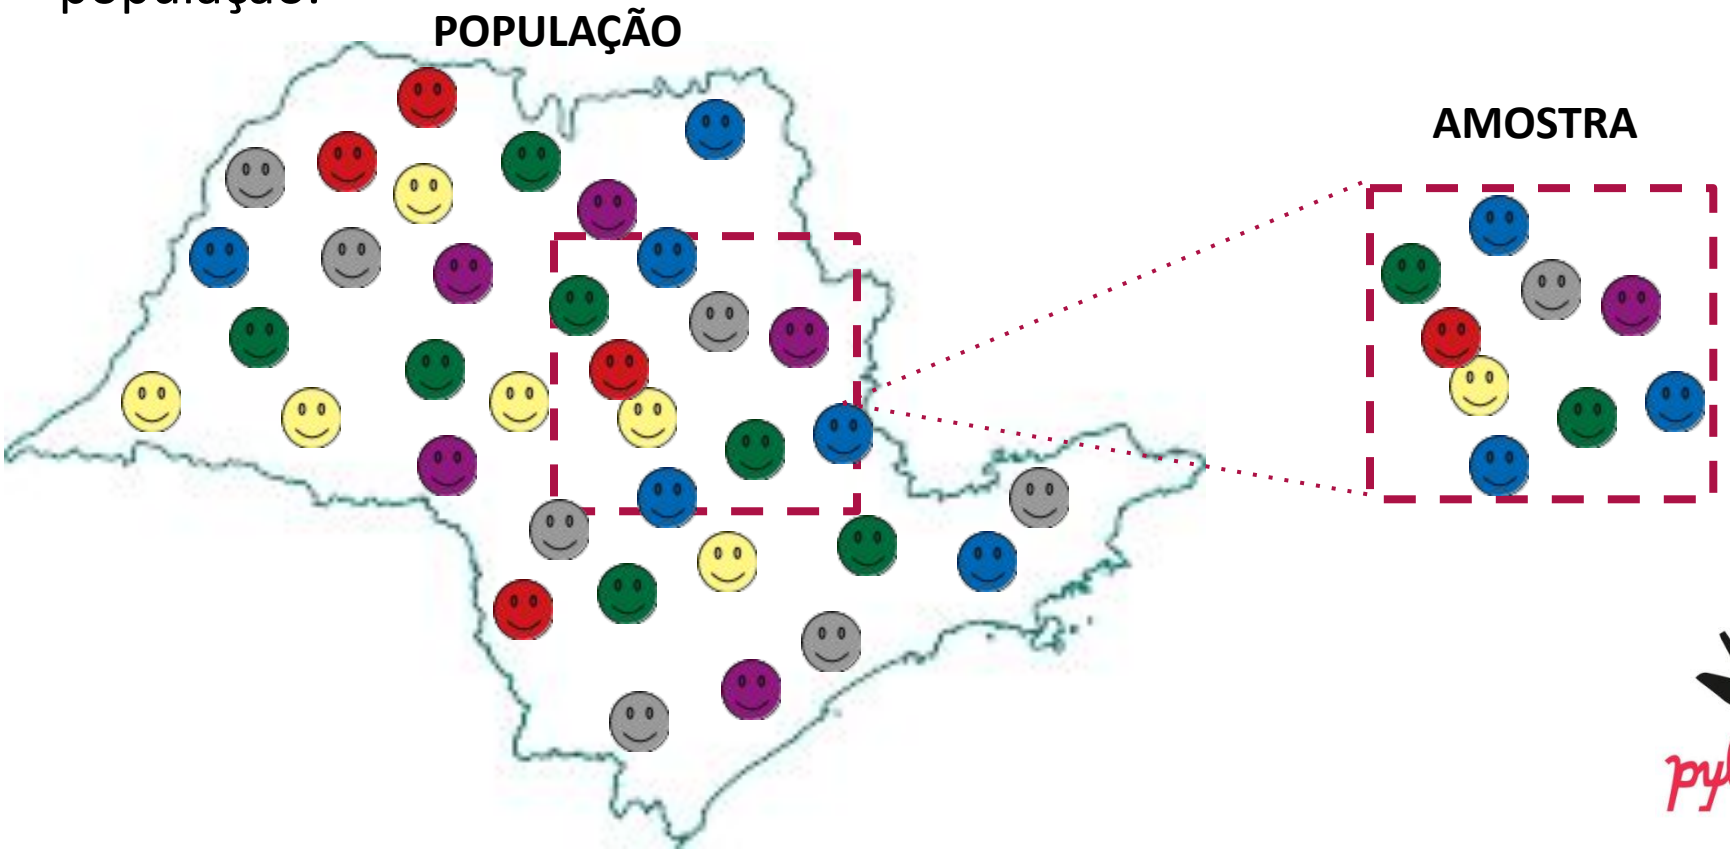

pyladies São Paulo

Média

A **média** é a soma de todos os elementos dividido pelo número de elementos.

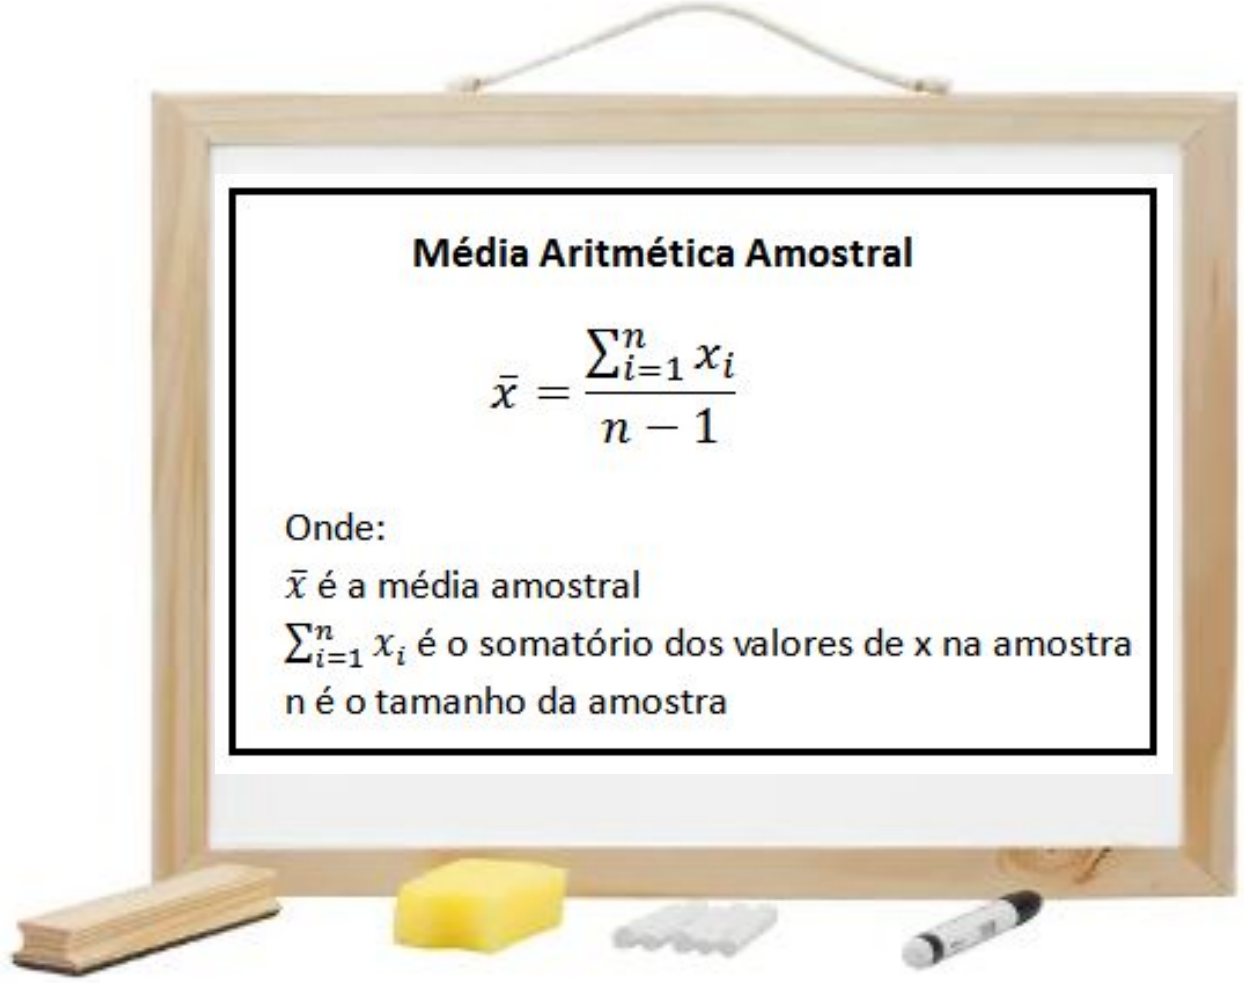

pyladies São Paulo

Média

Qual a renda média das meninas no dataframe dados_pyladies?

Para responder essa pergunta precisamos:

1º) Somar a renda mensal de todas as meninas;

```
valor = (3737.52 + 400.00 +  2366.14 +  2841.29 + 800.00 + 3433.02 + 2752.74 + 3682.33 + 2359.28 +
         2119.15 + 3326.79 + 2684.05 + 3507.84 + 0.00 + 800.00)
```

2º) Dividir o valor obtido pelo total de meninas.

```
media = valor / 15
print(media)
```

```
2320.6766666666667
```

Ou seja, em média a Renda Mensal é de R$2.320,68.

pyladies São Paulo

Média

Codando fica:

nome_dataframe['coluna'].mean()

Média Renda Mensal:

```
dados_pyladies['Renda_Mensal'].mean()
```

```
2320.6766666666667
```

Média Idade:

```
dados_pyladies['Idade'].mean()
```

```
28.8
```

pyladies São Paulo

Moda

A **Moda** é aquele elemento que mais se repete na distribuição dos dados.

Estado Origem	Frequência
SP	11

Qual será a UF que mais se repete?

nome_dataframe['coluna'].mode()

```
[48]  dados_pyladies['Estado Origem '].mode()

      0    SP
      dtype: object
```

pyladies São Paulo

Mediana

Mediana é o valor do meio de um conjunto de dados ordenados.

- Para um conjunto com número ímpar de observações: é o valor que divide exatamente na metade esse conjunto.
- Para um conjunto com número par de observações: é a média dos dois valores do meio.

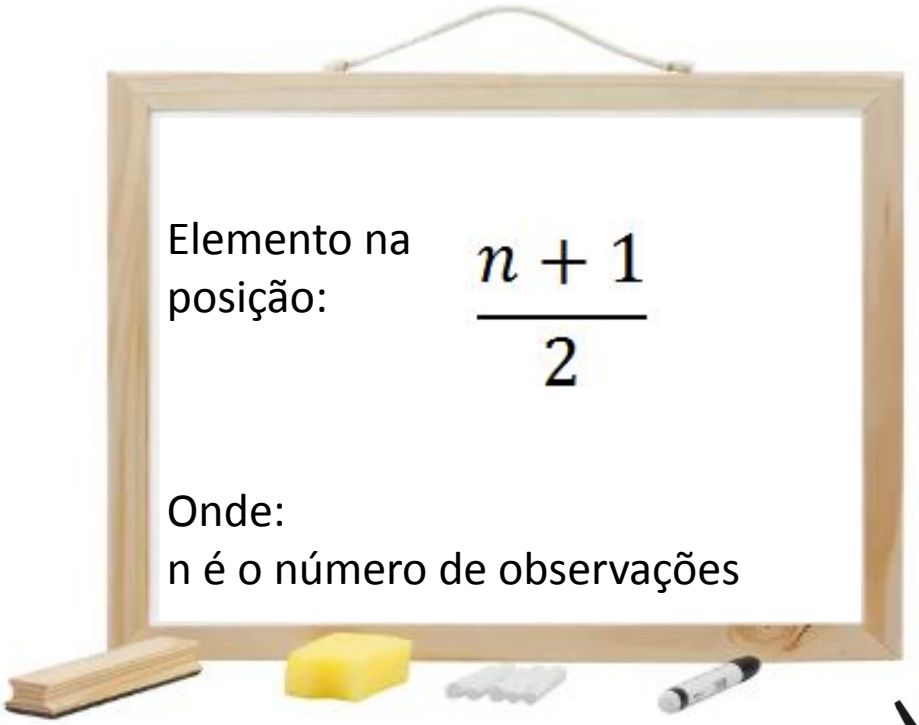

pyladies São Paulo

Mediana

Qual a Mediana quando observamos a idade das meninas?

Para responder essa pergunta precisamos:

1º) Ordenar os dados do menor para o maior valor;

2º) Selecionar o valor mediano dos dados.

Idade														
16	23	23	24	25	25	27	29	30	31	34	34	36	36	39

Observamos que a Mediana não é influenciada pelo valor baixo de idade.

pyladies São Paulo

Mediana

Codando fica:

nome_dataframe['coluna'].median()

Idade Mediana:

```
[50]  dados_pyladies['Idade'].median()

      29.0
```

Salário Mediano:

```
dados_pyladies['Renda_Mensal'].median()

2684.05
```

pyladies São Paulo

Mas média e mediana são as mesmas coisas???

Como Média, Moda e Mediana se relacionam?

Falando brevemente sobre distribuições, há vários tipos de comportamento natural das medidas que observamos, um deles é a distribuição Normal.

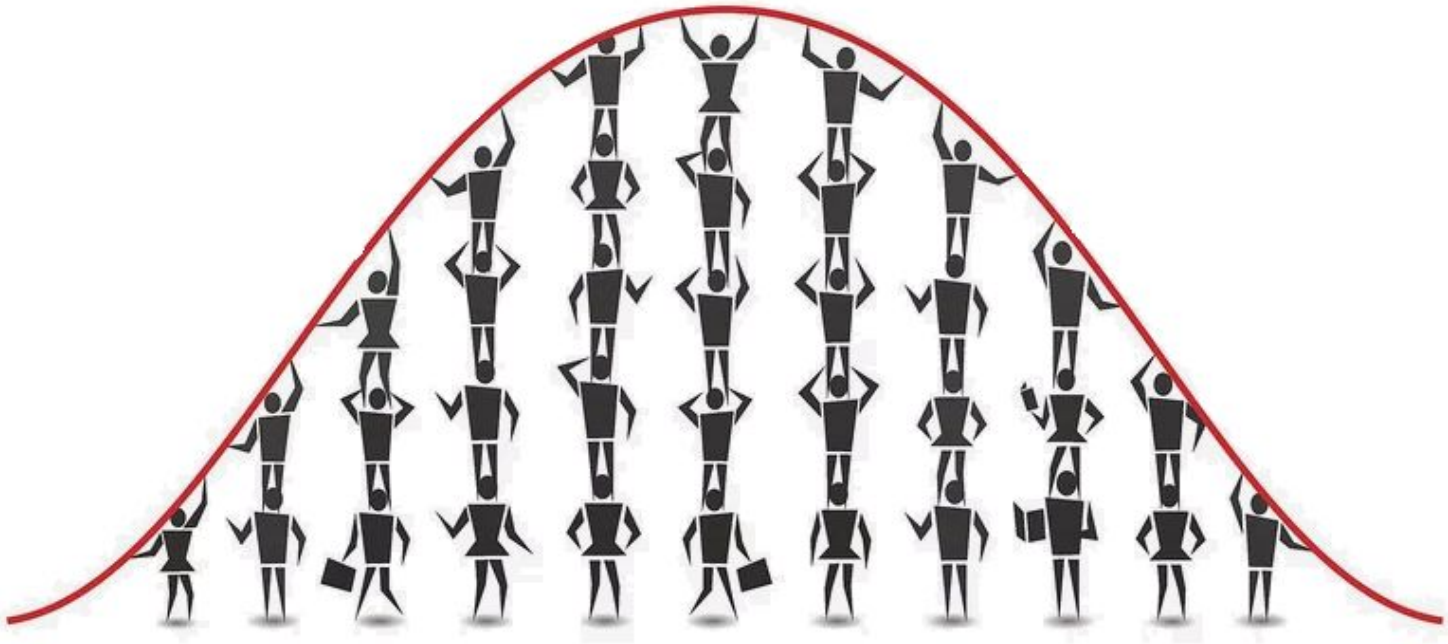

pyladies São Paulo

Como Média, Moda e Mediana se relacionam?

Em amostras normalmente distribuídas a Média, a Mediana e a Moda possuem valores próximos!

Se observarmos a renda mensal das meninas que trabalham com programação temos que a média e a mediana são muito próximas mesmo.

Média	R$ 2982,74
Mediana	R$ 2841,29

Se observarmos a idade das meninas, também obtemos valores de média e mediana próximos!

Média	Aprox. 29 anos
Mediana	29 anos

pyladies São Paulo

Quartis

Quartis são valores que dividem uma amostra de dados ordenados em quatro partes iguais.
Com eles você pode rapidamente avaliar a dispersão e a tendência central de um conjunto de dados, que são etapas importantes na compreensão dos seus dados.

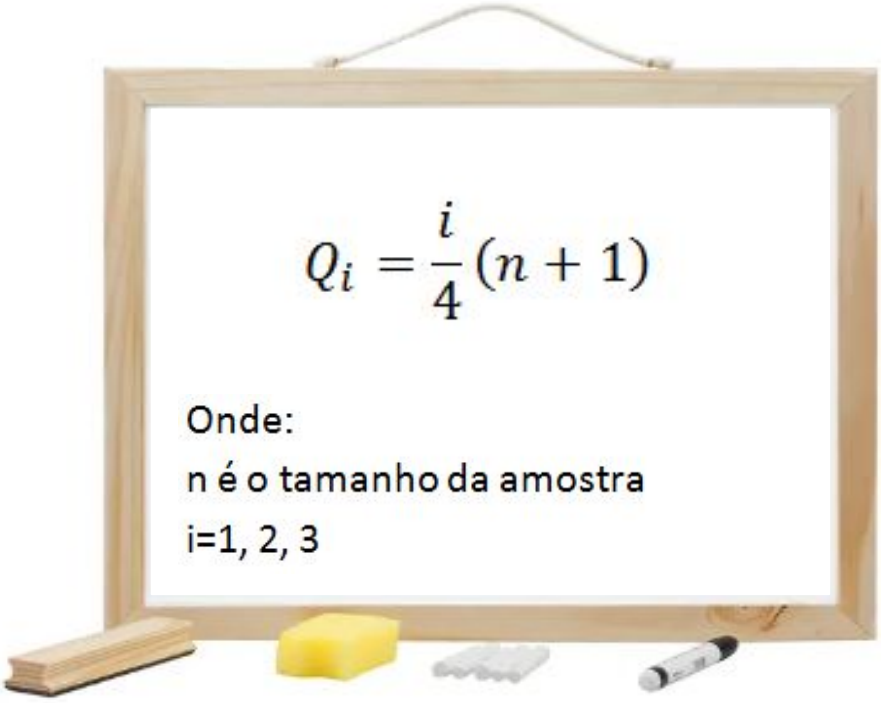

pyladies São Paulo

Quartis

Importante: para encontrar os quartis, os dados devem estar ordenados!

- 1º Quartil (Q1) - é onde estão 25% dos valores do conjunto de dados.
- 2º Quartil (Q2) - é onde estão até 50% dos valores, ou seja, a mediana!
- 3º Quartil (Q3) - é onde estão até 75% dos valores.

Isso quer dizer que:

✓ 25% dos valores do conjunto de dados são menores ou iguais ao Q1 e 75% dos valores são superiores ao Q1.

✓ 25% dos valores são superiores ou iguais ao Q3 e 75% dos valores são menores que Q3.

✓ 50% dos valores estão entre o 1º e o 3º Quartil.

pyladies São Paulo

Quartis

Codando fica:

nome_dataframe['coluna'].quantile()

25%

```
dados_pyladies.quantile(.25)

Idade            24.500
Escolaridade      3.000
Renda_Mensal   1459.575
Name: 0.25, dtype: float64
```

25% do conjunto de dados tem:
- idade até 24,5 anos;
- até a escolaridade 3;
- a renda mensal até R$ 1459, 58

75%

```
[21] dados_pyladies.quantile(.75)

Idade            34.000
Escolaridade      4.000
Renda_Mensal   3379.905
Name: 0.75, dtype: float64
```

75% do conjunto de dados tem:
- idade até 34 anos;
- até a escolaridade 4;
- a renda mensal até R$ 3379,91

pyladies São Paulo

Tabela de Frequência

Mas será que a renda mensal média varia com relação às demais características?

Para respondermos isso podemos criar uma tabela de frequência que nos mostrará a variação dos dados um pelo outro

Trabalha como Programadora	Soma Renda Mensal	Quantidade Meninas	Renda Mensal Média
S	32810,15	11	2982,74
N	2000	4	500,00

Característica: Trabalhar ou não com programação!

pyladies São Paulo

Tabela de Frequência - Usando o Groupby

O Pandas possui a função groupby que nos permite agrupar dados, como o exemplo anterior.

Ele nos permite visualizar rapidamente uma tabela de frequência.

nome_dataframe.groupby('coluna').método()

```
dados_pyladies.groupby('Trabalha_como_Programadora').count()
```

Trabalha_como_Programadora	Estado Origem	Idade	Escolaridade	Renda_Mensal
N	4	4	4	4
S	11	11	11	11

- alguns métodos não funcionam com o groupby, para saber mais consulte a documentação da biblioteca Pandas

pyladies São Paulo

Tabela de Frequência - Groupby

Há vários métodos que podem ser utilizados com o groupby.

Para contar os valores

```
nome_dataframe.groupby('coluna')['coluna'].value_counts()
```

Para somar valores

```
nome_dataframe.groupby('coluna')['coluna'].sum()
```

qual outro?

```
nome_dataframe.groupby('coluna')['coluna'].método()
```

pyladies São Paulo

Tabela de Frequência - Groupby + Agg

Podemos utilizar um Groupby com uma função Para isso utilizamos a função aggregation.

nome_dataframe.groupby('coluna')['coluna'].agg(['método', 'método'])

```
dados_pyladies.groupby('Trabalha_como_Programadora')['Renda_Mensal'].agg(['count','mean','median'])
```

Trabalha_como_Programadora	count	mean	median
N	4	500.000000	600.00
S	11	2982.740909	2841.29

pyladies São Paulo

Dispersão dos Dados

Dispersão dos Dados

Quando comparamos a média com o restante dos valores de uma váriavel, nós queremos entender o quanto aquele valor está distante da média.

ID	Estado Origem	Idade	Escolaridade	Trabalha como Programadora	Renda Mensal
1	SP	36	4	S	3737,52
2	SP	25	2	N	400,00

A média da Renda Mensal é de: **R$ 2320,68**

Se compararmos os valores da tabela acima percebemos o quanto eles variam em relação a média

pyladies São Paulo

Variância

Uma medida muito interessante para avaliarmos a dispersão dos dados é a **variância**!
Vimos que a média nos informa sobre a tendência central, mas a variância que indica como esses dados variam dentro de uma distribuição.

pyladies São Paulo

Variância

Será que as meninas que trabalham como programadora tem rendas parecidas? E as meninas que não trabalham como programadoras?

Para responder essa pergunta precisamos:

1º) Selecionar separadamente as meninas que trabalham ou não, como programadoras;
2º) Avaliar a soma dos desvios ao quadrado;
3º) Dividir essa soma pelo total de meninas considerado.

pyladies São Paulo

Variância

Renda Mensal (x)
3737,52
400
2366,14
2841,29
800
3433,02
2752,74
3682,33
2359,28
2119,15
3326,79
2684,05
3507,84
0
800
2684,05

$$s = \frac{(x1 - \text{média})^2 + (x2-\text{média})^2 + (x3-\text{média})^2}{(n-1)}$$

$$s = \frac{(3737,52-26805)^2 + (400-2684,05)^2 + \ldots\ldots}{(15-1)}$$

$$s = 1560989.622$$

pyladies São Paulo

Variância

Codando fica:

nome_dataframe['coluna'].var()

Variância Renda:

```
dados_pyladies['Renda_Mensal'].var()
```

```
1560989.6225666667
```

Variância Idade:

```
dados_pyladies['Idade'].var()
```

```
39.60000000000001
```

pyladies São Paulo

Desvio Padrão

O **desvio padrão** é uma medida que expressa o grau de dispersão de um conjunto de dados

Ele é a raiz quadrada da variância e a vantagem de utilizarmos esta medida é que o desvio padrão é expresso na mesma unidade dos dados, o que facilita a comparação.

pyladies São Paulo

Desvio Padrão

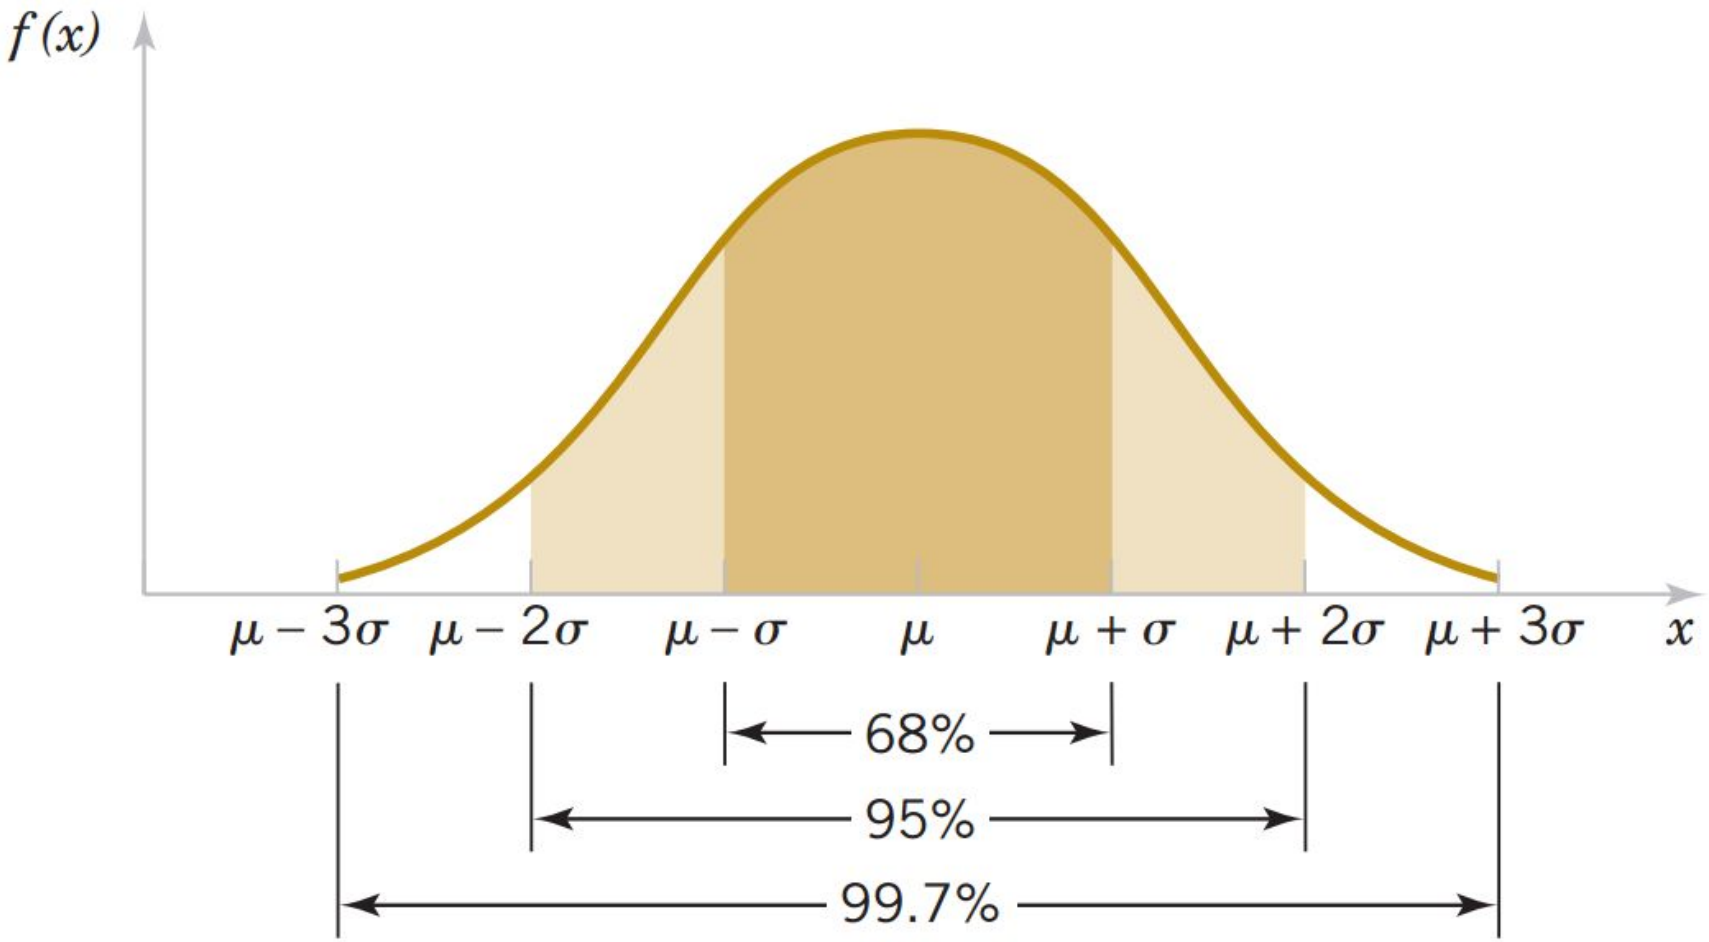

Fonte: https://www.inf.ufsc.br/~andre.zibetti/probabilidade/normal.html

pyladies São Paulo

Desvio Padrão

Codando fica:

nome_dataframe['coluna'].std()

Desvio Padrão Renda:

```
dados_pyladies['Renda_Mensal'].std()
```

```
1249.3957029567
```

Desvio Padrão Idade:

```
dados_pyladies['Idade'].std()
```

```
6.292853089020 91
```

pyladies São Paulo

Por fim! Describe

Para conseguirmos visualizar as medidas centrais e de dispersão de um conjunto de dados, nós podemos utilizar o método describe.

nome_dataframe.describe()

```
[14] dados_pyladies.describe()
```

	Idade	Escolaridade	Renda_Mensal
count	15.000000	15.000000	15.000000
mean	28.800000	3.266667	2320.676667
std	6.292853	1.099784	1249.395703
min	16.000000	1.000000	0.000000
25%	24.500000	3.000000	1459.575000
50%	29.000000	3.000000	2684.050000
75%	34.000000	4.000000	3379.905000
max	39.000000	5.000000	3737.520000

pyladies São Paulo

Introdução à Visualização dos Dados

Visualização de Dados - Gráficos

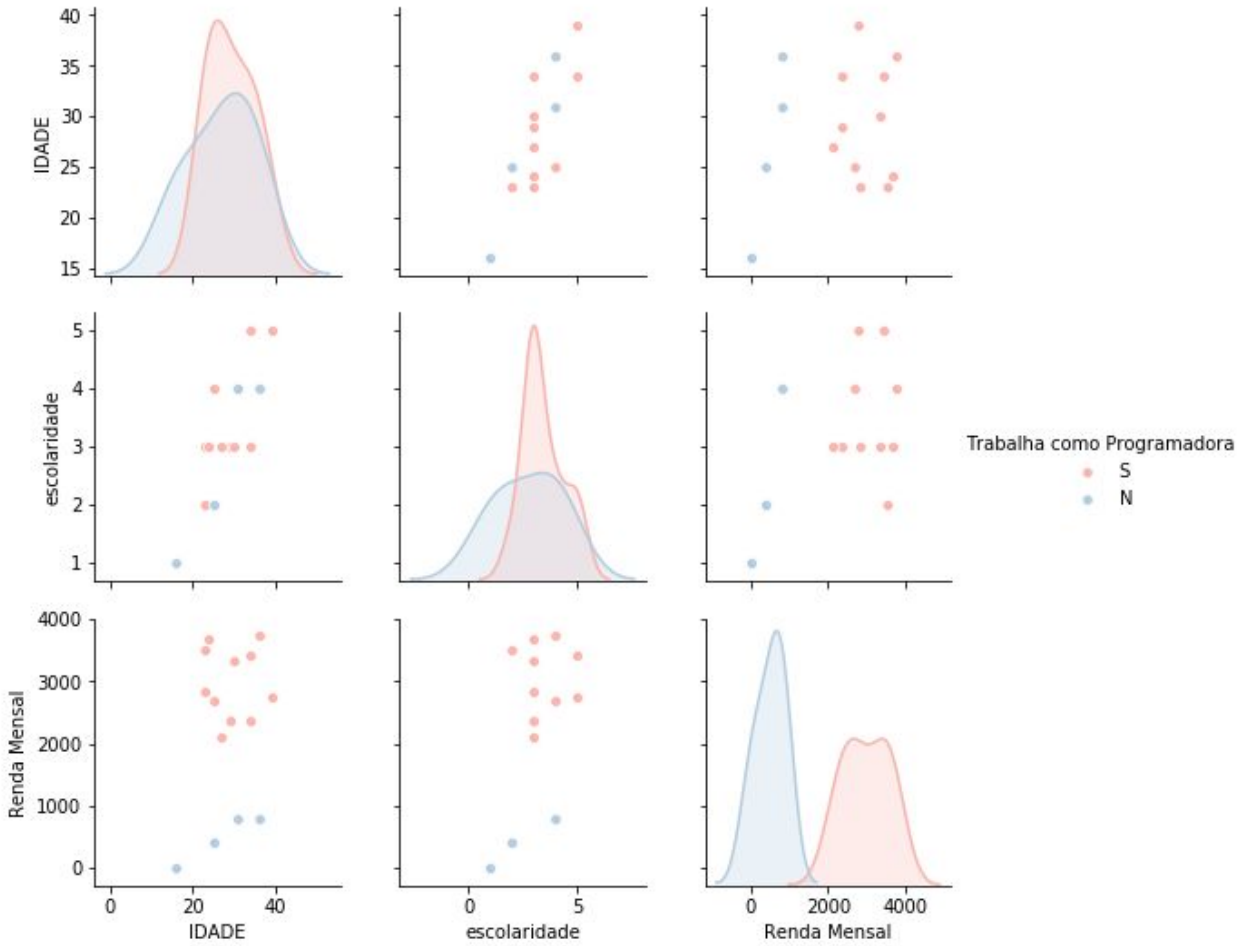

pyladies São Paulo

Visualização de Dados - Gráficos

Histograma

O Histograma é um gráfico que representa a distribuição de frequências de uma variável numérica contínua.

nome_dataframe['coluna'].plot.hist()

```
dados_pyladies['Renda_Mensal'].plot.hist();
```

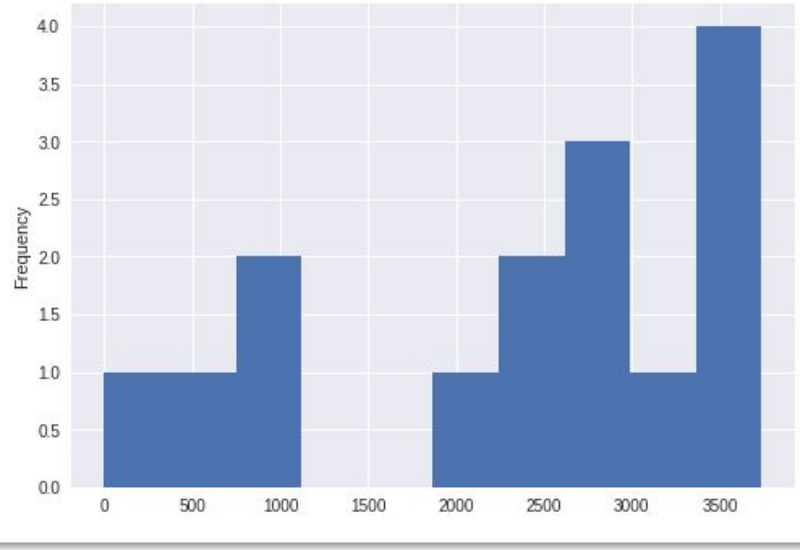

pyladies São Paulo

Visualização de Dados - Gráficos

Histograma

pandas.DataFrame.hist

`DataFrame.hist(data, column=None, by=None, grid=True, xlabelsize=None, xrot=None, ylabelsize=None, yrot=None, ax=None, sharex=False, sharey=False, figsize=None, layout=None, bins=10, **kwds)` [source]

Make a histogram of the DataFrame's.

A histogram is a representation of the distribution of data. This function calls `matplotlib.pyplot.hist()`, on each series in the DataFrame, resulting in one histogram per column.

data : *DataFrame*
The pandas object holding the data.

column : *string or sequence*
If passed, will be used to limit data to a subset of columns.

A função hist possui vários argumentos possíveis. Sempre que houver dúvidas sobre quais são os argumentos possíveis, consulte a documentação da função.

pyladies São Paulo

Visualização de Dados - Gráficos

BoxPlot

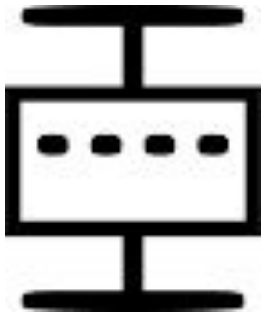

O boxplot nos permite avaliar a distribuição do conjunto de dados, utilizando como referência os quartis.

A “caixa principal” é formada pelo primeiro quartil, a mediana e terceiro quartil.

As hastes inferior e superior são os limites e podem ser calculadas da seguinte forma:

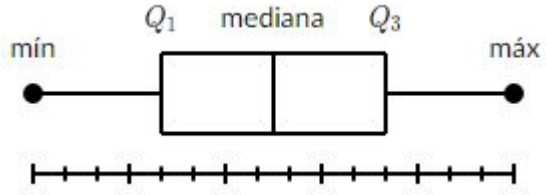

$$Limite\ inferior: Q_1 - 1{,}5(Q_3 - Q_1)$$

$$Limite\ superior: Q_3 + 1{,}5(Q_3 - Q_1)$$

pyladies São Paulo

Visualização de Dados - Gráficos

plt.boxplot(nome_dataframe['coluna'])

```
plt.boxplot(dados_pyladies['Renda_Mensal']);
```

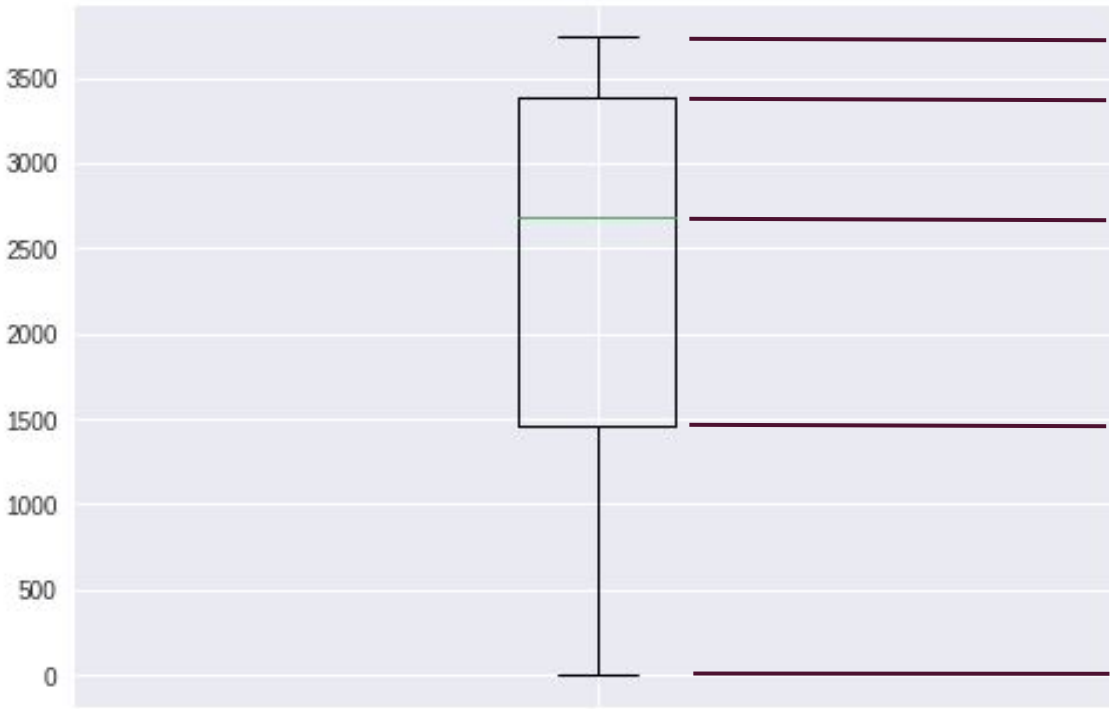

Valor Máximo

3º Quartil

Mediana

1º Quartil

Valor mínimo

pyladies São Paulo

Tipos de gráficos - Data to Viz

https://www.data-to-viz.com

pyladies São Paulo

Para saber mais

- Livro Guia Mangá de Estatística - Shin Takahashi
- Plataforma Kaggle - https://www.kaggle.com/
- Podcast Pizza de Dados - https://pizzadedados.com/
- Documentação Pandas - https://pandas.pydata.org/pandas-docs/stable/index.html
- Udacity - https://www.udacity.com/
- Canal EstaThiFisco https://www.youtube.com/channel/UC4jROkPjTvnXRkuo2GAwKXw
- Minerando Dados - http://minerandodados.com.br/
- Cientista de Dados com GIFs - https://paulovasconcellos.com.br/
- Data Hackers https://datahackers.com.br/
- Estatística Básica - P. A. Bussab, W. de O. Moretin - https://edisciplinas.usp.br/mod/resource/view.php?id=2425203

pyladies São Paulo

Obrigada!

Linkedin
angelicacustodio

PyLadiesSP

Pyladies São Paulo

pyladies
São Paulo

Mulheres que amam programar e ensinar Python